

浙江大学



课程名称	矩阵论
任课教师	程磊
实验名称	图像去噪
姓 名	赵一锟
学 号	3220104685
年级专业	22 级 信息工程
所在学院	信息与电子工程学院

目录

1 实验目的	3
2 实验原理	3
2.1 数学模型	3
2.2 BB 步长	3
2.3 核范数	4
3 实验内容-基础部分	5
3.1 加载图像，并进行图像预处理	5
3.2 计算函数值与梯度	5
3.3 梯度下降（constant 步长）	5
3.3.1 梯度下降基本格式	5
3.3.2 不同正则化系数下的降噪结果比较	6
3.3.3 梯度与函数值收敛性分析	6
3.3.4 psnr 值分析	7
4 实验内容-选做部分	8
4.1 BB 步长相关分析	8
4.2 图像存在缺失值	8
5 总结与反思	10

1 实验目的

利用Tikhonov 正则化模型，将图像去噪问题描述为一个优化问题。结合课上学习到的优化知识，用梯度下降法对问题进行求解，获得去掉噪声后的图像。具体任务和示例如后面各小节所示，要求提交一份代码以及报告，说明各任务是如何实现的，以及自己的理解。

2 实验原理

2.1 数学模型

假设有一张带噪声的图片 $Y \in \mathbb{R}^{m \times n}$ ，它和真实图片的关系为 $Y = X + E$ ，其中 $X \in \mathbb{R}^{m \times n}$ 是真实图片， E 是高斯白噪声($E_{ij} \sim N(0, \sigma^2)$)。图像去噪任务就是在给定带噪声图片 Y 的情况下，估计真实图片 X （实际中真实图片是未知的，已知的只有带噪声的图片，这里给出真实图片是为了方便计算 PSNR 衡量去噪效果）。假设估计得到的真实图片表示为 X_1 。在Tikhonov 正则化模型中， X_1 可以通过求解下面的优化问题得到：

$$X_1 = \arg \min \frac{1}{2} \|X - Y\|_F^2 + \lambda (\|D_1(X)\|_F^2 + \|D_2(X)\|_F^2)$$

其中 X 是优化变量， $D_1(X)$ 和 $D_2(X)$ 分别表示 X 在水平和垂直方向上的向前差分， λ 为正则系数。

函数形式说明：

- $\frac{1}{2} \|X - Y\|_F^2$ ：保持数据的一致性。它的作用是让去噪声后的图像 X 尽可能接近带有噪声的图像 Y ，原因是去掉噪声后，图像的主要信息应与观测噪声图像保持一致。
- $\lambda (\|D_1(X)\|_F^2 + \|D_2(X)\|_F^2)$ ：正则化项抑制噪声。 $D_1(X)$ 和 $D_2(X)$ 分别表示 X 在水平和垂直方向上的向前差分，通过最小化这些差分的平方和们可以使得图像变得平滑，抑制图像中的高频噪声。参数 λ 控制正则化的强度。如果 λ 较大，模型会更倾向于平滑图像，去除噪声；如果 λ 较小，则更强调与观测图像的相似性。
- 因此，该损失函数通过平衡数据一致性和图像平滑性来实现图像去噪。

在图像处理中，差分算子可以理解为一阶导数的离散化，而差分的导数可以理解为二阶导数的离散化，用拉普拉斯算子来描述：

$$[L(X)]_{ij} = X_{i+1,j} + X_{i-1,j} + X_{i,j+1} + X_{i,j-1} - 4X_{ij}$$

于是 $f(X)$ 的导数可以表示为：

$$\frac{df(X)}{dX} = X - Y - 2\lambda L(X)$$

2.2 BB 步长

考虑梯度下降法的格式：

$$\begin{aligned} x^{k+1} &= x^k - D^k \nabla f(x^k) \\ D^k &= \alpha_k I \end{aligned}$$

BB 方法选取的 α_k 是如下两个最优问题之一的解：

$$\min \|\alpha y^{k-1} - s^{k-1}\|^2$$

$$\min \|y^{k-1} - \alpha^{-1} s^{k-1}\|^2$$

$$s^{k-1} = x^k - x^{k-1}$$

$$y^{k-1} = \nabla f(x^k) - \nabla f(x^{k-1})$$

可以解得上述最优问题的解为：

$$\alpha_{BB1}^k = \frac{(s^{k-1})^T y^{k-1}}{(y^{k-1})^T y^{k-1}}$$

$$\alpha_{BB2}^k = \frac{(s^{k-1})^T s^{k-1}}{(s^{k-1})^T y^{k-1}}$$

因此 BB 方法的两种迭代形式为：

$$x^{k+1} = x^k - \alpha_{BB1}^k \nabla f(x^k)$$

$$x^{k+1} = x^k - \alpha_{BB2}^k \nabla f(x^k)$$

算法 6.2 非单调线搜索的 BB 方法

1. 给定 x^0 , 选取初值 $\alpha > 0$, 整数 $M \geq 0$, $c_1, \beta, \varepsilon \in (0, 1)$, $k = 0$.
 2. **while** $\|\nabla f(x^k)\| > \varepsilon$ **do**
 3. **while** $f(x^k - \alpha \nabla f(x^k)) \geq \max_{0 \leq j \leq \min(k, M)} f(x^{k-j}) - c_1 \alpha \|\nabla f(x^k)\|^2$ **do**
 4. 令 $\alpha \leftarrow \beta \alpha$.
 5. **end while**
 6. 令 $x^{k+1} = x^k - \alpha \nabla f(x^k)$.
 7. 根据公式(6.2.9)之一计算 α , 并做截断使得 $\alpha \in [\alpha_m, \alpha_M]$.
 8. $k \leftarrow k + 1$.
 9. **end while**
-

2.3 核范数

核范数是一种用于矩阵正则化的方法, 常用于处理低秩矩阵恢复等问题。在许多实际问题中, 我们希望找到一个低秩矩阵的近似解, 例如图像去噪。核范数的正则化通常用于鼓励矩阵的低秩结构, 低秩矩阵能更好地反映数据的内在结构和隐藏模式。直接使用矩阵的秩约束问题是一个 NP-hard 问题, 核范数提供了一种解决此问题的凸松弛方法, 因为核范数是秩函数的凸包逼近。

核范数倾向于将小奇异值压缩到接近零, 从而使得矩阵中的冗余信息被去除, 得到近似低秩的矩阵表示。这种效果在图像处理、信号处理等需要提取主要特征的场景中尤为显著。在矩阵补全问题(如推荐系统)中, 核范数正则化能在数据不完备的情况下有效地恢复矩阵的低秩结构。

给定一个矩阵 $X \in \mathbb{R}^{m \times n}$, 其核范数定义为所有奇异值的和, 即:

$$\|X\|_* = \sum_{i=1}^{\min(m, n)} \sigma_i$$

核范数的正则化模型:

$$\min_X \frac{1}{2} \sum_{(i,j) \in \Omega} (X_{ij} - Y_{ij})^2 + \lambda \|X\|_*$$

核范数的梯度计算: 假设 $X = U \Sigma V^T$, 则核范数的此梯度为:

$$\partial \|X\|_* = UV^T$$

3 实验内容-基础部分

3.1 加载图像，并进行图像预处理

使用 matlab 中的 `imread`、`rgb2gray`、`imshow` 函数加载灰度图像，并未图像添加 $\sigma^2 = 20$ 的高斯白噪声。




图 1 图像预处理

3.2 计算函数值与梯度

根据上述分析的数学建模中计算函数值与梯度的公式，用 matlab 具体实现如下：

```
1. function [value, grad] = gradient_value(x, y, lambda)
2. %函数用于计算函数值和梯度，用于后面的梯度下降算法
3. %输入：x, y, lambda（正则系数）
4. %输出：函数值 value，梯度 grad
5. %差分矩阵计算
6. D1x = x(:, [2:end, end]) - x;
7. D2x = x([2:end, end], :) - x;
8.
9. %函数值计算
10. value = 0.5 * norm(x - y, 'fro')^2 + lambda * (norm(D1x, 'fro')^2 + norm(D2x, 'fro')^2);
11.
12. %梯度计算
13. L_x = x([2:end, end], :) + x([1, 1:end-1], :) + x(:, [2:end, end]) + x(:, [1, 1:end-1]) - 4 * x;
14. grad = x - y - 2 * lambda * L_x;
15. end
```

通过上述过程，我们可以计算函数当前的函数值与梯度值。

3.3 梯度下降（constant 步长）

3.3.1 梯度下降基本格式

$$x^{k+1} = x^k - \mu_k \nabla f(x^k)$$
$$\mu_k = \text{constant}$$

具体 matlab 实现代码如下：

```

1. for iter = 1:iters
2.     %计算函数值及梯度
3.     [value, grad] = gradient_value(x, y, lambda);
4.     %更新 x
5.     x = x - step * grad;

```

3.3.2 不同正则化系数下的降噪结果比较



图 2 step=0.1 固定步长降噪

可以观察到，随着 λ 的增大，降噪后的图片越来越平滑，与理论情况相符。

3.3.3 梯度与函数值收敛性分析

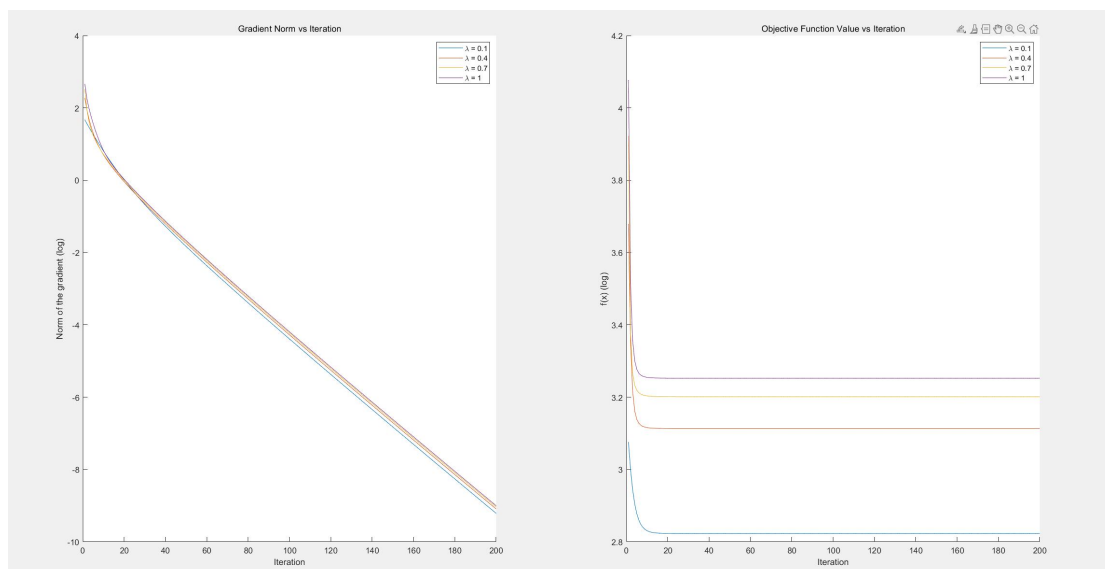


图 3 constant 收敛曲线 (step = 0.1)

我们可以看到，所有不同的 λ 值对应的梯度范数都在逐渐减小，并且在 200 次迭代后趋近收敛。不同的 λ 值对收敛速度的影响相对较小。无论 λ 的取值是 0.1、0.4、0.7 还是 1，梯度范数的下降曲线几乎是相似的。




图 4 不同 step 收敛曲线

如上图所示，当 $\text{step} = 0.3$ 时，梯度下降算法不收敛。因此，步长对收敛速度起到的影响更大。

3.3.4 psnr 值分析




图 5 psnr 值 ($\text{step}=0.1$)

psnr 值分析中， λ 越小，psnr 值相对越高，这与观测到的降噪平滑程度效果图略有不同。

4 实验内容-选做部分

4.1 BB 步长相关分析

结合在实验原理部分的分析，我们对梯度下降算法作出以下修改，采用 BB 步长进行优化：

```
1. %BB 步长
2. if iter > 1
3.     s = x - x_prev;
4.     y_diff = grad - grad_prev;
5.     step = (s(:)' * s(:)) / (s(:)' * y_diff(:) + eps);
6. end
7.
8. %更新 x
9. x_prev = x;
10. grad_prev = grad;
11. x = x - step * grad;
```

相比于 constant 步长，BB 步长的主要优势在于算法的收敛速度快，可节约大量时间。




图 6 不同步长方法的收敛性

通过比较可以看到，BB 步长在 50—60 次迭代后梯度下降基本完成，而 constant 步长仍在继续。

4.2 图像存在缺失值

在有噪声的情况下，假设图像存在缺失值，即智能观测到部分有噪声的数据。图像的优化问题即可以建模为：

$$\arg \min_{\mathbf{X}} \frac{1}{2} \|\mathbf{Y} - \mathbf{O} * \mathbf{X}\|_F^2 + \lambda \phi(\mathbf{X})$$

使用原来的梯度下降法，降噪后的结果为全噪声图像，这是由于图像存在缺失值造成的数据缺失问题，因此我们令 $\phi(\mathbf{X})$ 为核范数来优化正则化模型，使其能够对低秩矩阵有更好的逼近。对损失函数的函数值与梯度值计算方法进行更新：

```
1. % 核范数梯度计算
```



```

2. [U, S, V] = svd(x, 'econ');
3. S_threshold = max(S - lambda, 0); % 奇异值软阈值化
4. x_nuclear = U * S_threshold * V';
5.
6. value = 0.5 * norm(0 .* (y - x), 'fro')^2 + lambda * sum(diag(S)); % 损失函数值的计算
7.
8. % 梯度计算
9. grad = 0 .* (x - y) + (x - x_nuclear);

```

接下来，利用 **BB** 步长进行梯度下降，再将得到的图像使用原梯度下降算法进行梯度下降，得到最终降噪的结果，如下图：




图 7 存在缺失时的降噪结果

根据初步的降噪结果，可以看到降噪后的图像相比原图像略显“朦胧”。接下来我们分析两次降噪的 **psnr**




图 8 存在缺失降噪 psnr

蓝色曲线为使用核范数进行逼近的 **psnr**，此时 **psnr** 仍然较小，但其解决了低秩矩阵求解的问题，橙色曲线为在核范数正则化的基础上，利用原梯度下降法进行降噪后的 **psnr**，可以看到此时 **psnr** 的值上升到了 25 左右。两次结合运用，降噪效果较好。

5 总结与反思

在这次图像降噪大作业的学习中，我学会了一些基础的图像降噪方法，运用了课上所学习的 Tikhonov 正则化模型、奇异值分解、梯度下降等等理论知识。在实际的工程运用中，这些看似枯燥的公式在图像处理的过程中也展现出了灵动的趣味，令人回味无穷。

美中不足的是，选做部分处理信息缺失的图像降噪问题的结果仍有很大的提升空间。与此同时，EVD 分解的时间复杂度为立方级别，使用 matlab 进行梯度下降的迭代过程中耗时较长。

矩阵论的课堂是大学中难能可贵的教学时刻，感谢程磊老师细致的讲解与指导，也很幸运遇见一群志同道合的人共勉。

I love matrix.